Análisis Clásico del Dataset DEFCON CTF 22 para Predicción del Próximo Paso

Estudio de Secuencias MSNA y Caracterización de Patrones de Ataque

Proyecto FONDECYT N°11221155
Análisis de Datos de Ciberseguridad - Línea Clásica

8 de julio de 2025

Resumen

Este reporte presenta un análisis exhaustivo y reflexivo del dataset DEFCON CTF 22 desde la perspectiva clásica de predicción del próximo paso en ataques de red. Se profundiza en la caracterización de secuencias Multi-Step Network Attack (MSNA), la interpretación de patrones de ataque, la detección de outliers y la discusión de estrategias de preprocesamiento para modelos de machine learning. Los resultados evidencian la riqueza y complejidad del dataset, así como los desafíos y oportunidades que ofrece para la investigación en predicción secuencial de ciberataques.

Índice

1. Introducción **3**
1.1. Contexto y relevancia del dataset 3

2. Metodología y procesamiento **3**

3. Resultados y análisis **3**
3.1. Distribución y características de las secuencias 3
3.2. Outliers y concentración de actividad 4
3.3. Dinámica temporal y multi-adversario 4
3.4. Patrones de transición y matrices globales 5
3.5. Análisis por atacante y victimización 6
3.6. Evolución de ataques en el tiempo 7
3.7. Patrones de victimización 8
3.8. Comparación de estrategias de preprocesamiento 8

4. Discusión **9**

5. Conclusiones **9**

6. Agradecimientos **9**

1. Introducción

La predicción del próximo paso en ataques de red es un reto central en ciberseguridad, especialmente en escenarios realistas donde los ataques se desarrollan como secuencias complejas y adaptativas. El dataset DEFCON CTF 22, proveniente de una competencia internacional de alto nivel, constituye una fuente única para estudiar estos fenómenos. En este reporte, se analiza en profundidad la estructura, dinámica y patrones de las secuencias MSNA, así como las implicancias para el desarrollo de modelos predictivos.

1.1. Contexto y relevancia del dataset

El dataset original fue generado a partir de la competencia DEFCON 22 CTF (2014), donde 20 equipos de élite participaron en un entorno de ataque-defensa durante tres días. Cada equipo debía proteger y atacar servicios vulnerables, generando un tráfico de red realista y altamente dinámico. La extracción y estandarización de alertas mediante Snort IDS permitió transformar 285GB de tráfico en un corpus estructurado de más de 5 millones de alertas, organizadas en ventanas temporales y secuencias multi-paso.

2. Metodología y procesamiento

El procesamiento del dataset implicó varias etapas críticas: extracción de alertas, organización temporal, identificación de roles (atacante/víctima), y agrupación en secuencias MSNA. Este pipeline permitió no solo estructurar los datos para análisis clásico, sino también preservar la riqueza temporal y contextual de los ataques. El preprocesamiento incluyó la detección y manejo de outliers, el balanceo de clases y la preparación de secuencias para modelos LSTM y Transformer.

3. Resultados y análisis

3.1. Distribución y características de las secuencias

El análisis de las secuencias MSNA revela una notable heterogeneidad en la longitud y composición de los ataques. La mayoría de las secuencias presentan longitudes moderadas, pero existen outliers que concentran una cantidad desproporcionada de alertas. Esta dispersión es ilustrada en la Figura 1, donde se observa una distribución asimétrica y la presencia de valores extremos. Estos outliers no solo representan desafíos para el modelado, sino que también pueden corresponder a eventos de ataque coordinado o a errores de instrumentación.

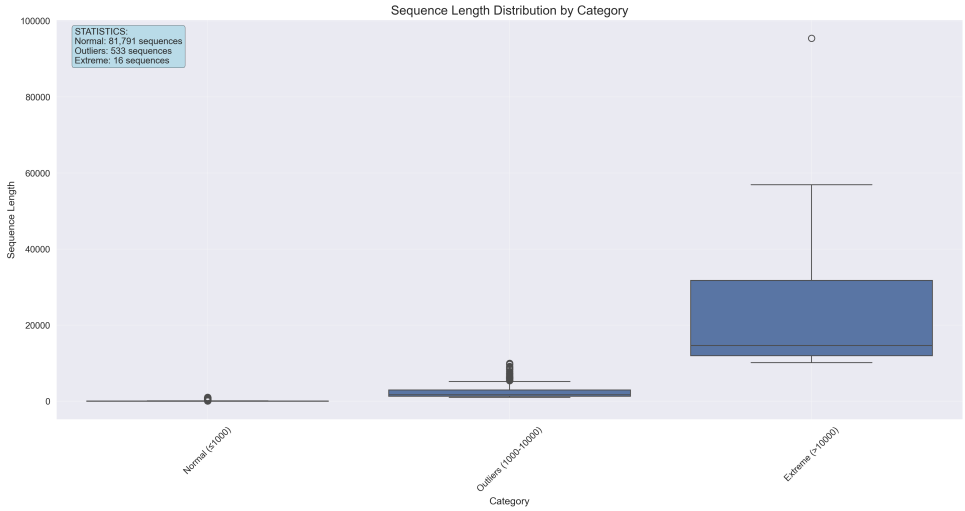

Figura 1: Distribución de longitudes de secuencia MSNA. La asimetría y los valores extremos reflejan la complejidad y variabilidad de los ataques.

3.2. Outliers y concentración de actividad

La presencia de secuencias extremadamente largas o cortas es un fenómeno recurrente en el dataset. En la Figura 2 se visualizan estas secuencias atípicas, que pueden indicar tanto ataques masivos como artefactos de la recolección de datos. La interpretación de estos outliers requiere un análisis cuidadoso, ya que pueden distorsionar las métricas globales y afectar el entrenamiento de modelos si no se gestionan adecuadamente.

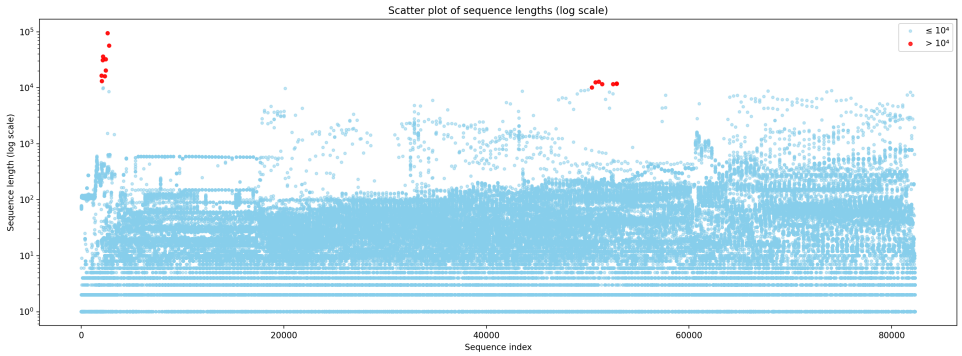

Figura 2: Secuencias atípicas (outliers) en el dataset, visualizadas en escala logarítmica. Los puntos rojos destacan secuencias con longitud inusualmente alta.

3.3. Dinámica temporal y multi-adversario

El análisis temporal muestra que la actividad de ataque no es uniforme a lo largo de la competencia. Existen ventanas de tiempo con picos de actividad multi-adversario, reflejando momentos de mayor intensidad o coordinación entre atacantes. La Figura 3 ilustra cómo la dinámica de los ataques varía por ronda, permitiendo identificar patrones de escalamiento o defensa exitosa.

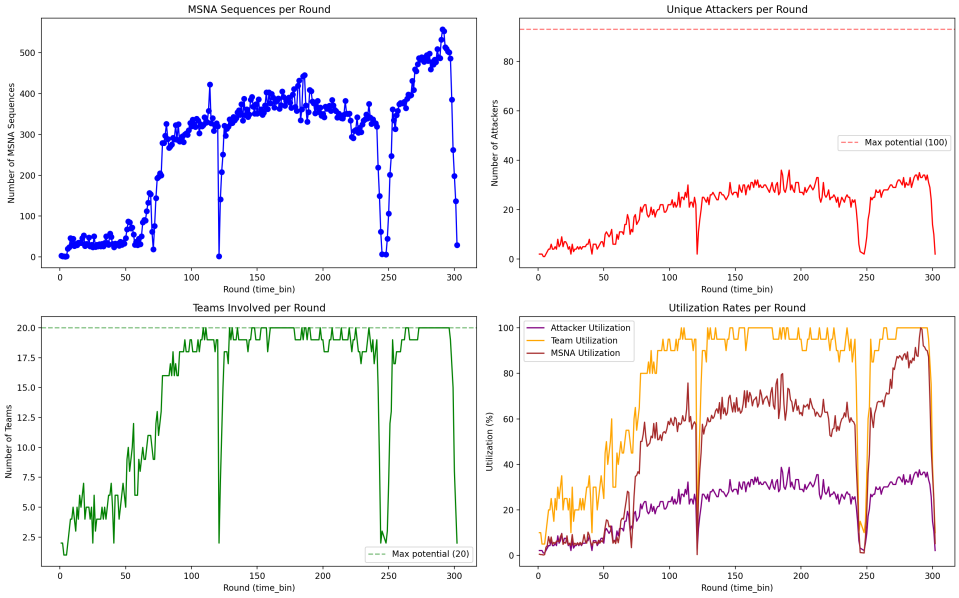

Figura 3: Evolución temporal de la actividad multi-adversario. Los picos reflejan momentos de alta intensidad y posible coordinación entre equipos.

3.4. Análisis por atacante y victimización

El comportamiento de los atacantes individuales varía considerablemente. Las Figuras 5 y 6 presentan matrices de transición para dos atacantes específicos, evidenciando estilos y estrategias diferenciadas. Este nivel de análisis permite identificar tanto patrones persistentes como adaptaciones tácticas a lo largo de la competencia.

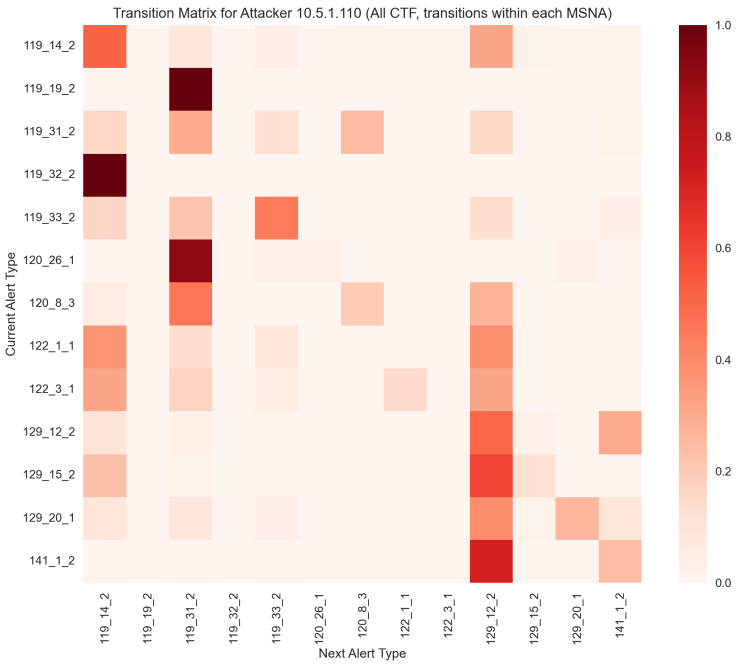

Figura 4: Matriz de transición para el atacante 10.5.1.110. Se observan rutas preferidas y posibles especializaciones en ciertos tipos de ataque.

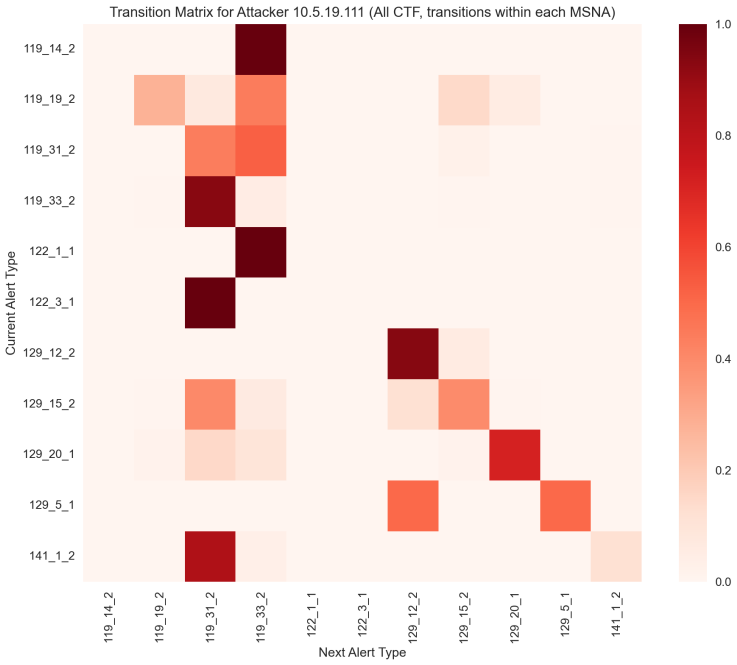

Figura 5: Matriz de transición para el atacante 10.5.19.111. Se aprecian diferencias notables respecto a otros atacantes, lo que sugiere estrategias particulares.

3.5. Evolución de ataques en el tiempo

Los timelines (worm plots) permiten visualizar la evolución de los ataques entre pares atacante-víctima. Las Figuras 7 y 8 muestran ejemplos de cómo los patrones de alerta se desarrollan a lo largo del tiempo, revelando tanto persistencia como cambios abruptos en la estrategia ofensiva.

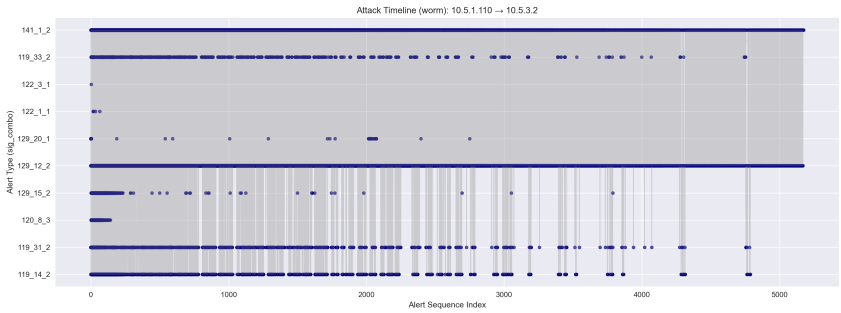

Figura 6: Evolución temporal de tipos de alerta para el par 10.5.1.110 → 10.5.3.2. Se observan fases de ataque sostenido y periodos de inactividad.

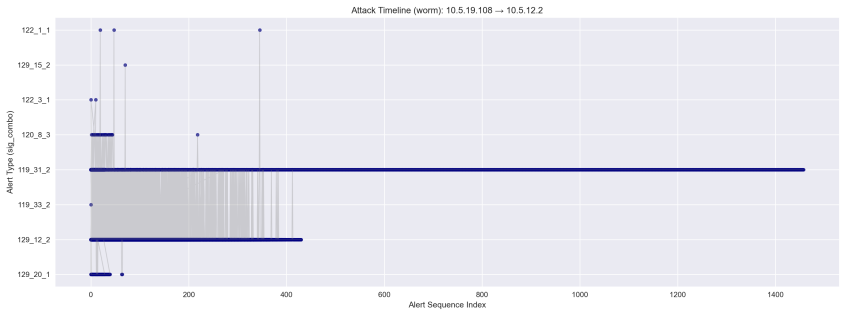

Figura 7: Evolución temporal de tipos de alerta para el par 10.5.19.108 → 10.5.12.2. Cambios abruptos pueden indicar adaptación táctica o respuesta defensiva.

3.6. Patrones de victimización

La distribución de alertas recibidas por cada víctima, mostrada en la Figura 9, evidencia que algunos equipos fueron blanco de ataques mucho más intensos que otros. Este hallazgo sugiere la existencia de estrategias de focalización y posibles debilidades explotadas de manera reiterada.

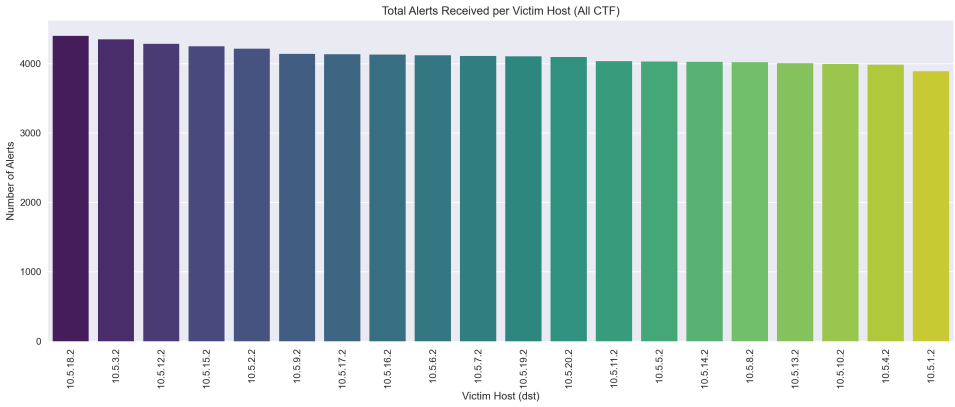

Figura 8: Distribución de alertas recibidas por cada víctima. La asimetría indica que ciertos equipos fueron atacados de forma desproporcionada.

3.7. Comparación de estrategias de preprocesamiento

La preparación de los datos para modelos de machine learning requiere decisiones críticas sobre filtrado, padding y balanceo de clases. La Figura 10 compara el impacto de diferentes estrategias, mostrando cómo afectan la distribución de secuencias y la diversidad de clases objetivo. Un preprocesamiento adecuado es esencial para evitar sesgos y mejorar la capacidad predictiva de los modelos.

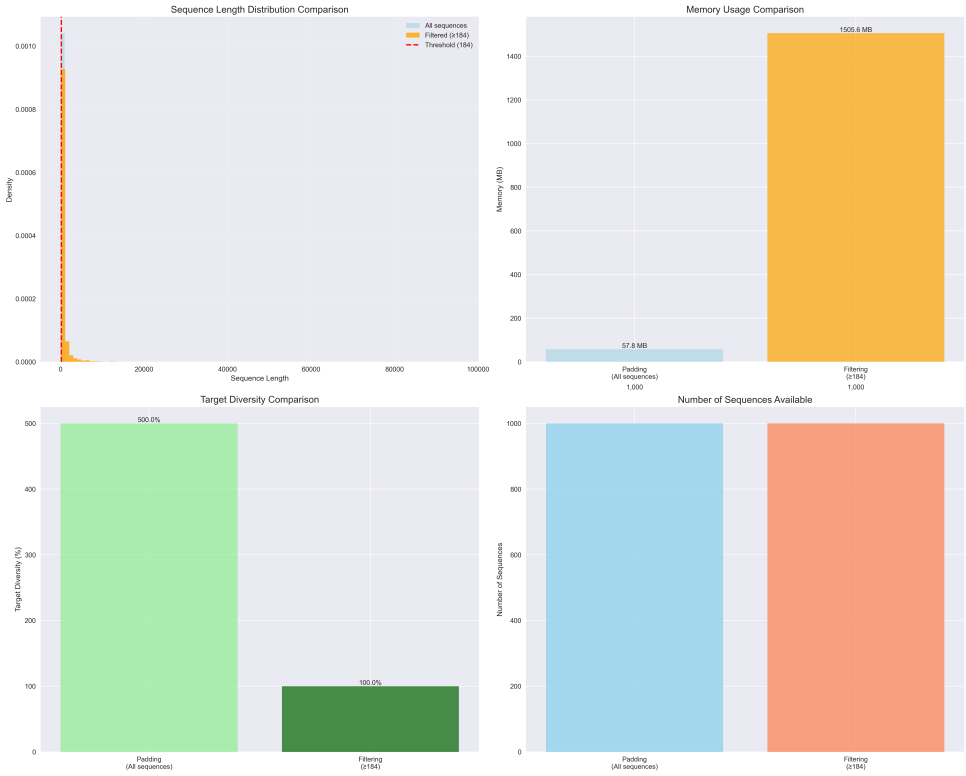

Figura 9: Comparación de estrategias de preprocesamiento: filtrado vs padding y su impacto en la distribución de secuencias.

4. Discusión

El análisis detallado del dataset DEFCON CTF 22 revela tanto su potencial como sus desafíos. La riqueza de patrones, la presencia de outliers y la variabilidad temporal ofrecen oportunidades únicas para el desarrollo de modelos avanzados, pero también exigen un preprocesamiento cuidadoso y una validación rigurosa. La interpretación de los resultados sugiere que los modelos LSTM y Transformer pueden beneficiarse de la estructura secuencial y la diversidad de patrones, siempre que se gestionen adecuadamente los casos extremos y el desbalance de clases.

5. Conclusiones

El estudio clásico del dataset DEFCON CTF 22 demuestra que es posible caracterizar y modelar secuencias de ataque complejas a partir de datos reales de competencia. La combinación de análisis estadístico, visualización avanzada y reflexión crítica proporciona una base sólida para futuras investigaciones en predicción del próximo paso y defensa proactiva en ciberseguridad.

6. Agradecimientos

Este trabajo fue financiado por ANID/FONDECYT N°11221155. Los datos del DEFCON CTF 22 fueron proporcionados por la competencia de Capture The Flag, permitiendo este análisis pionero en predicción del próximo paso en ataques de red.